



## Apache Pig / Apache Hive





## Comparar el valor d'opinió obtinguda amb el camp label

a> Fitxer CSV amb els següents camps: (text, label, opinio\_optinguda, comparació) A on comparació serà un camp booleà, aquest serà true si l'opinio\_obtinguda es correspon amb l'etiqueta.

De la taula generada amb l'script feim el següent select on a la columna score interpretam els valors majors a 0 com a positius (1) i els menors com a negatius (0), també incloem una columna on comparam l'opinio\_optinguda amb el label.

SELECT id, text, label,

CASE WHEN score > 0 THEN 1 ELSE 0 END AS opinio\_optinguda,

CASE

WHEN label = (CASE WHEN score > 0 THEN 1 ELSE 0 END) THEN 1

ELSE 0

**END AS correcte** 

FROM practica\_pig\_hive

ilian life is the local bank manager is a fussy little man peering at the world through a pair of thick spectacles. It is he who takes the initiative in forming the Homme Guard unit and who appoints himself its manamader. He is pompous officious with an exaggerated sense of his own importance and of his own powers of leadership the sort of man who does not suffer fools gladly. (And in George Rainmarings world-view the erm fool covers most of the rest of the human race). He does however have his good qualities. He is notivated by a genuine patriotic idealism and is capable of great physical courage shown in his encounter with the Germans. (Are hydrocytes) and in the property of the property of

text	label	opinio_optinguda	correcte
· ·			
d with this one.	0	0	1
ith either one.	1	1	1
it was shot on.	0	0	1
PS games more than i do.7/10 STARS	1	1	1
ocused on what might have been.	0	1	0
was well worth it.	0	1	0
this as one of the best movie of the year	1	1	1
	ith either one. it was shot on. PS games more than i do.7/10 STARS ocused on what might have been. was well worth it.	ith either one. 1 it was shot on. 0 PS games more than i do.7/10 STARS 1 coused on what might have been. 0 was well worth it. 0	d with this one.  0 0  ith either one.  1 1  it was shot on.  0 0  PS games more than i do.7/10 STARS  1 1  coused on what might have been.  0 1  was well worth it.  0 1





### **b>** Fitxer CSV a on es farà un recompta a on la comparació sigui true i un recompta a on la comparació sigui false.

A partir del select del punt anterior sumam els valors de la columna comparació per obtenir un recompte dels correctes. Per al recompte d'incorrectes restam al total en nombre de valoracions correctes.

```
SELECT
SUM(label) AS n_correctes,
COUNT(label)-SUM(label) AS n_incorrectes
FROM(
SELECT id, text, label,
CASE WHEN score > 0 THEN 1 ELSE 0 END AS opinio_optinguda,
CASE
WHEN label = (CASE WHEN score > 0 THEN 1 ELSE 0 END) THEN 1
ELSE 0
END AS correcte
FROM practica_pig_hive
) AS opinions
```

#### 2473,2442

	n_correctes	n_incorrectes
1	2473	2442

# 2. Relacionar les pel·lícules amb les opinions

a> Descarregar el fitxer d'un repositori de dades.

El fitxer amb les pel·lícules que es descarregarà és el següent:

https://raw.githubusercontent.com/JoanBF20/Pelis\_csv/main/pelis.csv

#### Descarregam el fitxer:

wget https://raw.githubusercontent.com/JoanBF20/Pelis\_csv/main/pelis.csv





#### **Apache Pig / Apache Hive** Joan Barceló Fiol 31/03/23

#### Visualitzam el contingut del fitxer:

```
cat pelis.csv
```

```
0,Avatar

1,Avengers: Endgame

2,Avatar: The Way of Water

3,Titanic

4,Star Wars: Episodio VII - El despertar de la Fuerza

5,Avengers: Infinity War

6,Spider-Man: No Way Home

7,Jurassic World

8,El rey león

9,The Avengers

10,Fast and Furious 7

11,Top Gun: Maverick

12,Frozen II

13,Avengers: Age of Ultron

14,Black Panther

15,Harry Potter y las reliquias de la muerte: parte 2
```

#### b> Carregar aquest fitxer el hdfs.

hdfs dfs -put pelis.csv /user/cloudera/pig\_analisis\_opinions

#### Modificam els permisos del fitxer:

hdfs dfs -chmod 777 /user/cloudera/pig\_analisis\_opinions/pelis.csv

#### Per importar les dades a una taula. Primer cream una taula nova:

```
CREATE TABLE IF NOT EXISTS default.pelis (
id int,
film string)
ROW FORMAT DELIMITED
FIELDS TERMINATED BY ',';
```

```
Logging initialized using configuration in file:/etc/hive/conf.dist/hive-log4j.properties
OK
Time taken: 0.515 seconds
WARN: The method class org.apache.commons.logging.impl.SLF4JLogFactory#release() was invoked.
WARN: Please see http://www.slf4j.org/codes.html#release for an explanation.
```

#### Carregam les dades del fitxer a la taula creada prèviament:

LOAD DATA INPATH '/user/cloudera/pig\_analisis\_opinions/pelis.csv' INTO TABLE default.pelis;

```
Logging initialized using configuration in file:/etc/hive/conf.dist/hive-log4j.properties
Loading data to table default.pelis
Table default.pelis stats: [numFiles=10, totalSize=4168]
OK
Time taken: 1.099 seconds
WARN: The method class org.apache.commons.logging.impl.SLF4JLogFactory#release() was invoked.
WARN: Please see http://www.slf4j.org/codes.html#release for an explanation.
```







c> Crear un fitxer CSV amb els següents camps (nom\_pelicula, numero\_opinions, opinió\_optinguda, nlabels\_positius, nlabels\_negatius, opinio\_obtinguda\_text) A on opinio\_obtinguda\_text serà el valor que creguis més adequat per cada pel·lícula.

Obtingut a partir de l'anàlisi del text de les crítiques cinematogràfiques.

Realitzam un subselect on feim el join de les 2 taules i a partir d'aquest agrupam per pel·lícula i n'extreim els camps demanats, el nom, el recompte de labels positius i negatius, el nombre d'opinions, l'opinió obtinguda i l'opinió obtinguda en text.

```
SELECT film,
SUM(label) AS nlabels_positius,
COUNT(label)-SUM(label) AS nlabels_negatius,
COUNT(label) AS n_opinions,
CASE WHEN AVG(score) > 0 THEN 1 ELSE 0 END AS opinio_optinguda,
CASE WHEN AVG(score) > 0 THEN 'Positiu' ELSE 'Negatiu' END AS opinio_optinguda_text
FROM (
SELECT film, practica_pig_hive.* FROM practica_pig_hive
INNER JOIN pelis ON practica_pig_hive.id=pelis.id
) AS joined_tables
GROUP BY film
```

```
"Avatar",576,747,1323,1,Positiu
"Avatar: The Way of Water",1368,1548,2916,1,Positiu
"Avengers: Age of Ultron",1647,1521,3168,1,Positiu
"Avengers: Endgame",1530,1440,2970,1,Positiu
"Avengers: Infinity War",1584,1404,2988,1,Positiu
"Black Panther",1575,1593,3168,1,Positiu
"El rey león",1512,1602,3114,1,Positiu
"Fast and Furious 7",1647,1386,3033,1,Positiu
"Frozen II",1530,1440,2970,1,Positiu
"Harry Potter y las reliquias de la muerte: parte 2",702,648,1350,1,Positiu
"Jurassic World",1368,1485,2853,1,Positiu
"Spider-Man: No Way Home",1377,1476,2853,1,Positiu
"Star Wars: Episodio VII - El despertar de la Fuerza",1476,1458,2934,1,Positiu
"The Avengers",1314,1467,2781,1,Positiu
"Titanic",1521,1287,2808,1,Positiu
"Top Gun: Maverick",1530,1476,3006,1,Positiu
```

		film	nlabels_positius	nlabels_negatius	n_opinions	opinio_opti
,	1	"Frozen II"	170	160	330	1
	2	"Avengers: Age of Ultron"	183	169	352	1
	3	"El rey león"	168	178	346	1
	4	"The Avengers"	146	163	309	1





d> Crear un fitxer CSV amb els següents camps (nom\_pelicula, opinio\_labels, opinio\_text) A on opinio\_labels serà un valor obtingut a partir del camp labels que podrà tenir els següents valors de 0,1,2,3,4. A on opinio\_text serà un valor obtingut a partir del camp opinio\_obtinguda\_text que podrà tenir els següents valors de 0,1,2,3,4.

Realitzam un subselect on feim el join de les 2 taules i a partir d'aquest feim la mitjana de la columna label que ens retornarà un valor entre 0 i 1 i li assignem un valor de 0 a 4, a partir de la mitja de la columna score que ens retorna valors entre -1125 fins a 2375 i li assignem un valor de 0 a 4.

```
SELECT film,
CASE
  WHEN AVG(label) > 0.80 THEN 4
  WHEN AVG(label) > 0.60 THEN 3
  WHEN AVG(label) > 0.40 THEN 2
  WHEN AVG(label) > 0.20 THEN 1
  ELSE 0
END AS opinio_labels,
CASE
  WHEN AVG(score) > 1675 THEN 4
  WHEN AVG(score) > 975 THEN 3
  WHEN AVG(score) > 275 THEN 2
  WHEN AVG(score) > -425 THEN 1
  ELSE 0
END AS opinio_text
FROM (
  SELECT film, practica_pig_hive.* FROM practica_pig_hive
  INNER JOIN pelis ON practica_pig_hive.id=pelis.id
) AS joined_tables
GROUP BY film
```

```
"Avatar",2,1
"Avatar: The Way of Water",2,1
"Avengers: Age of Ultron",2,1
"Avengers: Endgame",2,1
"Avengers: Infinity War",2,1
"Black Panther",2,1
"El rey león",2,1
"Fast and Furious 7",2,1
"Frozen II",2,1
"Harry Potter y las reliquias de la muerte: parte 2",2,1
"Jurassic World",2,1
"Spider-Man: No Way Home",2,1
"Star Wars: Episodio VII - El despertar de la Fuerza",2,1
"The Avengers",2,1
"Titanic",2,1
"Top Gun: Maverick",2,1
```





#### **Apache Pig / Apache Hive** Joan Barceló Fiol 31/03/23

Big Data Aplicat

		film	opinio_labels	opinio_text
,	1	"Frozen II"	2	1
	2	"Avengers: Age of Ultron"	2	1
	3	"El rey león"	2	1
	4	"The Avengers"	2	1
	5	"Avengers: Endgame"	2	1

